DeepLearning-HW2

學號:313834004 姓名:周彥宏

實作 ResNet model

這次在實作 ResNet model，選擇使用 layer-18 的架構下去做. ResNet 主要架構其實就是 CNN 的擴展，會多出一個叫做 Residualblock 的 Class 來去作出所謂的誤差計算，如下圖所示:

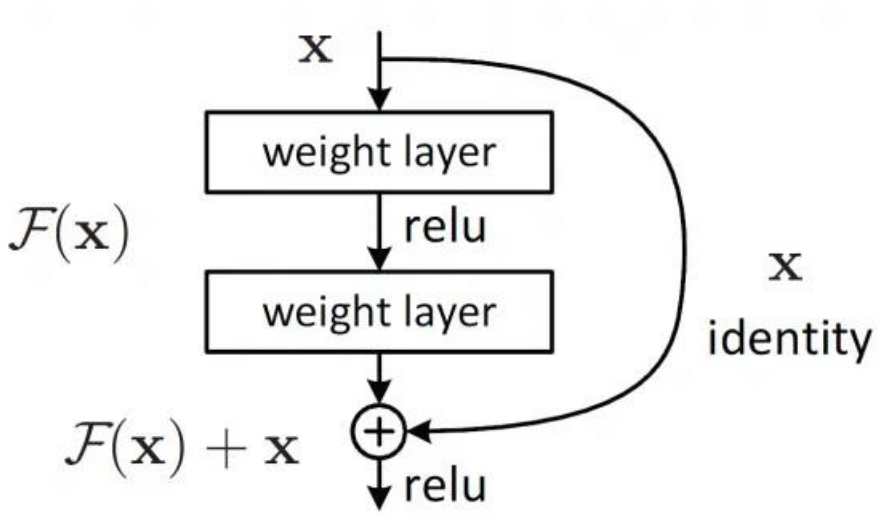

主要是將計算出的 x 套入公式, F(x)+x 是從 F(x) = H(x) – x 所推導出來，主要是用來解決 CNN 的一個問題，當無法一次算出最接近的答案，那可以通過誤差值來一階段一階段的找出最相近的答案，得出 H(x) – x = 0 使其等價。

ResNet 不同層數的架構:

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
conv2_x	56×56	3×3 max pool, stride 2				
		$\begin{bmatrix} 3\times3, 64 \\ 3\times3, 64 \end{bmatrix}\times2$	$\begin{bmatrix} 3\times3, 64 \\ 3\times3, 64 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix}\times3$
conv3_x	28×28	$\begin{bmatrix} 3\times3, 128 \\ 3\times3, 128 \end{bmatrix}\times2$	$\begin{bmatrix} 3\times3, 128 \\ 3\times3, 128 \end{bmatrix}\times4$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix}\times4$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix}\times4$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix}\times8$
conv4_x	14×14	$\begin{bmatrix} 3\times3, 256 \\ 3\times3, 256 \end{bmatrix}\times2$	$\begin{bmatrix} 3\times3, 256 \\ 3\times3, 256 \end{bmatrix}\times6$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix}\times6$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix}\times23$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix}\times36$
conv5_x	7×7	$\begin{bmatrix} 3\times3, 512 \\ 3\times3, 512 \end{bmatrix}\times2$	$\begin{bmatrix} 3\times3, 512 \\ 3\times3, 512 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix}\times3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

這次在設計的是 ResNet-18 的架構，會有四個 block_layer 並且每層的 Residualblock 數量為 2，如果要架設 18 以上的就需要做修改．值得注意的是當使用到 50 層以上後，所使用的就不會是 Residualblock 而會變成是 Bottleneck Block,會有三層 conv．但由於太大架構的網路怕跑不動，因此這次實作只使用 18 層的 ResNet 來實作。

而在 input size 上，為了符合架構圖上所提供的 size，所以在資料前處理上一律將 image resize(224,224)．關於 input size 經過 conv, maxpool 後，會產生的 outputsize 我有將計算過程寫成程式方便我在使用不同網路時也可以很好計算.(計算程式)

資料前處理

訓練集:

下圖是我所做的資料前處理還有 Data augmentation 得部分，我使用了隨機垂直翻轉，機率則是用預設的 0.5．**主要原因為:** 我觀察了花的資料後，覺得做水平翻轉對於花這種對稱形狀並沒有很大的意義，因此我選擇了垂直翻轉，讓一些花可能有上下分明的特稱可以有更多的資料.

接著我使用了隨機選轉，角度區間設為[-10,10]，主要是想讓花透過不同角度會有機會去呈現不一樣的特徵點.

最後就是做歸一化和 resize，歸一化的部分，我不使用範例的 0.5，而是上網參照一些不一樣的人所做的實驗設置，透過輸出來觀察花的圖片，最後發現當我使用這主數據時，最能夠將花的本體顏色凸顯出來，並且可以有效的將背景色變為接近統一色調.Resize 則是上面提到為了符合網路架構的 input size 所設定.

驗證集和測試集:

在這部分我只有做了簡單的歸一化和 Resize，相關原因和訓練集相同.

嘗試步驟:

嘗試過將圖片做灰階來判斷，原先想法是灰階圖，就不會注重花的顏色，而是會去學習花的本體特徵，但最後效果顯示十分不佳．發現其實**顏色也是一個非常重要的特徵點，對於這份資料集來說.**

```
train_transform = transforms.Compose([
    transforms.RandomVerticalFlip(),
    transforms.RandomRotation(10),
    transforms.ToTensor(),
    transforms.Normalize((0.4914, 0.4822, 0.4465),(0.2023, 0.1994, 0.2010)),
    transforms.Resize([224,224])
])

test_transform = transforms.Compose([
    transforms.ToTensor(),
    transforms.Normalize((0.4914, 0.4822, 0.4465),(0.2023, 0.1994, 0.2010)),
    transforms.Resize([224,224])
])
```

資料集大小

資料集切分是照著 Flower102 內建的去切分，唯一要注意的是**我的訓練集**使用的是 **Flower102 的測試集**，而**我的測試集**是使用 **Flower102 的訓練集**.
主要原因為資料量大小差異過大，所以選擇使用 6149 筆資料的來做訓練.

```
print(f'trainset size: {len(trainset)}')
print(f'valset size: {len(valset)}')
print(f'testset size: {len(testset)}')
```

✓ 0.0s

```
trainset size: 6149
valset size: 1020
testset size: 1020
```

模型參數&訓練參數&優化器選擇&lr_scheduler

Activation function	ReLU	LeakReLU	Sigmod
Learning Rate	0.001	0.001	0.001
lr_scheduler	MultiStepLR (milestones=[40,70],gamma=0.2)	MultiStepLR (milestones=[40,70],gamma=0.2)	MultiStepLR (milestones=[40,70],gamma=0.2)

表(一)

模型參數:

在模型參數部分，都是依照 ResNet 論文的架構下去實作,並沒有額外新增或是減少 Conv, Pool, or BatchNorm layer,只有在設定 Activation function 時，選擇了表(一)三個來做,最後會有實作的比較圖表.
會想要選擇主要的原因是, ReLU 和 LeakReLU 是 **Non-Saturated function**，而 Sigmod 則是 **Saturated function**. 而 Non-Saturated function 優點則是可以解決**梯度消失**的問題，也可以加快收斂的速度，因此選擇兩種不同的來做比較.
而另外會選擇 LeakReLU 是想要和 ReLU 做比較，因為 ReLU 有個缺點是他會將所有 x 內的**負值都設為 0**，很容易造成神經元死掉. 而 LeakReLU 則是會將負值賦予一個非零的斜率，我想要觀察這兩者會不會有很大的差異.

優化器選擇:

在優化器的部分，我選擇 Adam 而不是 SGD. SGD 是用微分的方法算出梯度，並往梯度方向去更新參數，而 Adam 有保留 SGD 的方法，可以使用過去的梯度方向做梯度的速度調整，和利用過去梯度的平方值來去做 learning rate 的調整.

lr_scheduler

接著我想要根據 epoch 的次數來去減少我的 learning rate，因此我使用了 lr_scheduler 這個方法，相關設定在表(一). 這次使用的是 MultiStep，遞減倍數設為 0.2, Learning Rate 分布如下圖一樣:

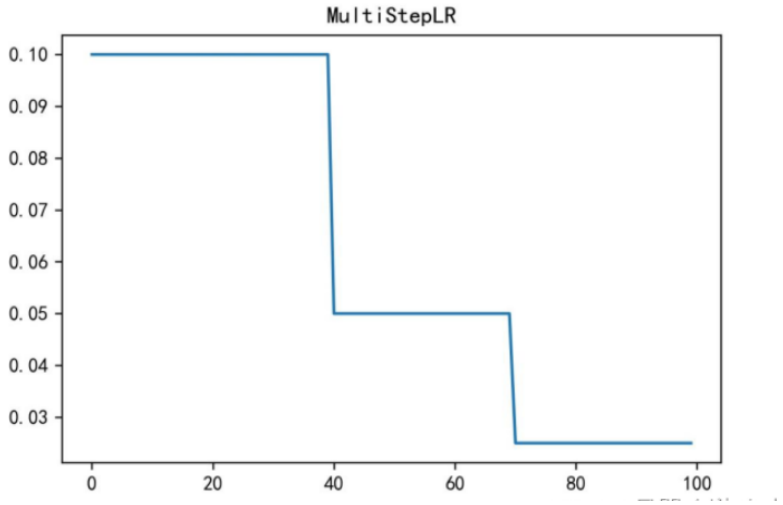

可以讓我的 Learning Rate 照著 epoch 次數來做調整.

實驗結果:

Case/feature	Activation function	Epochs	Accuracy
Case1	ReLU	100	75%
Case2	Sigmod	100	46%
Case3	LeakReLU	100	74%
Example	ReLU	100	36%

Case1:

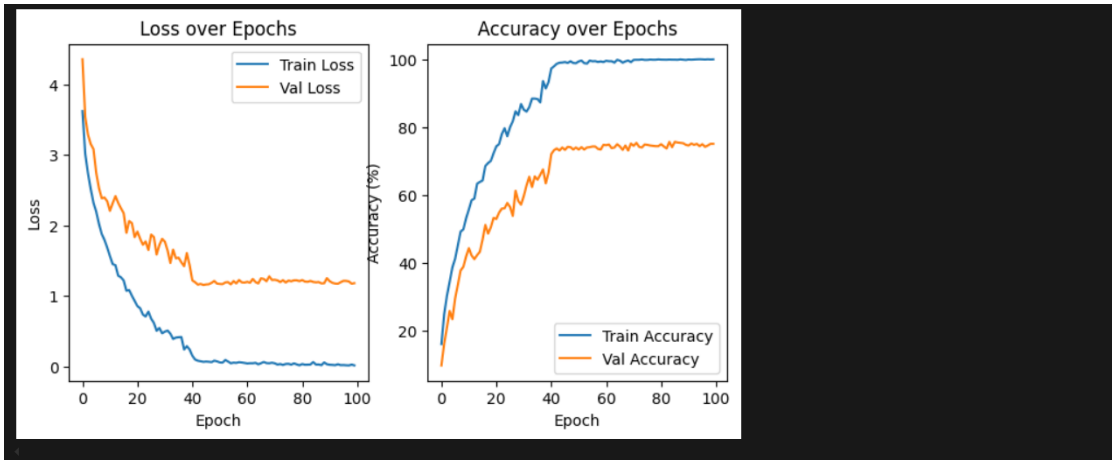

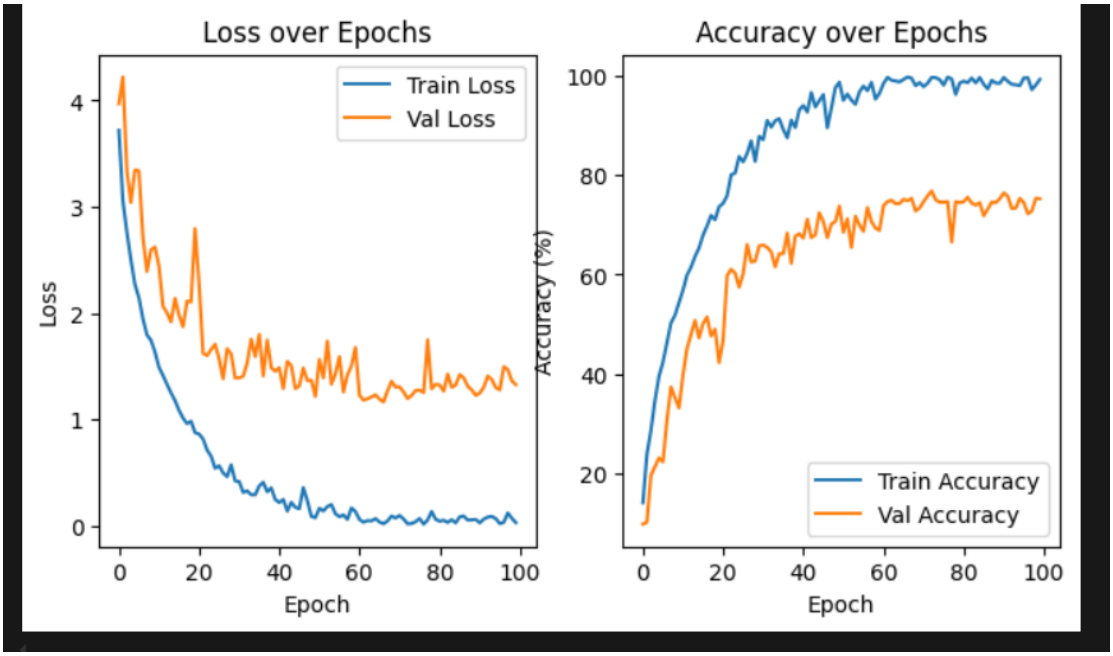

可以發現在訓練時, Loss 在 40 個 epochs 之後有一個很明顯的下降並慢慢收斂, 是因為使用了 lr_scheduler 的關係, 在 40 次會調降 learning rate. 並最後收斂也是十分漂亮, 雖然準確率效果並不理想, 但不論是在驗證集或是訓練集的收斂上都是不錯的.另一張比較圖一樣是使用 MultiStepLR(miles[60],gamma=0.5), 一樣 Loss 在 60epochs 會有不錯的下降, 但是最後收斂因為 gamma 設 0.5 所以沒有收斂得很好. 後續會將數值改成 40,70 也是透過這張比較圖來決定.

Case2:

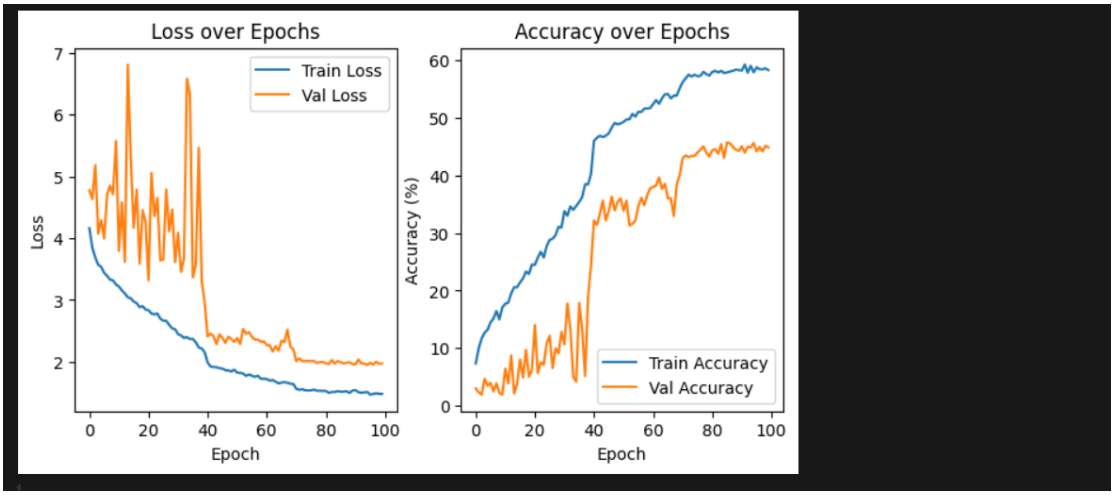

可以發現 case2 在使用 sigmod 的效果十分不好, 在訓練中 loss 雖然收斂的很不錯, 但是在驗證集可以很明顯發現前期的收斂效果非常不好, Loss 到最後也是十分高, 所以跟 ReLU 的比較可以說使用 ReLU 會來的好很多.

Case3:

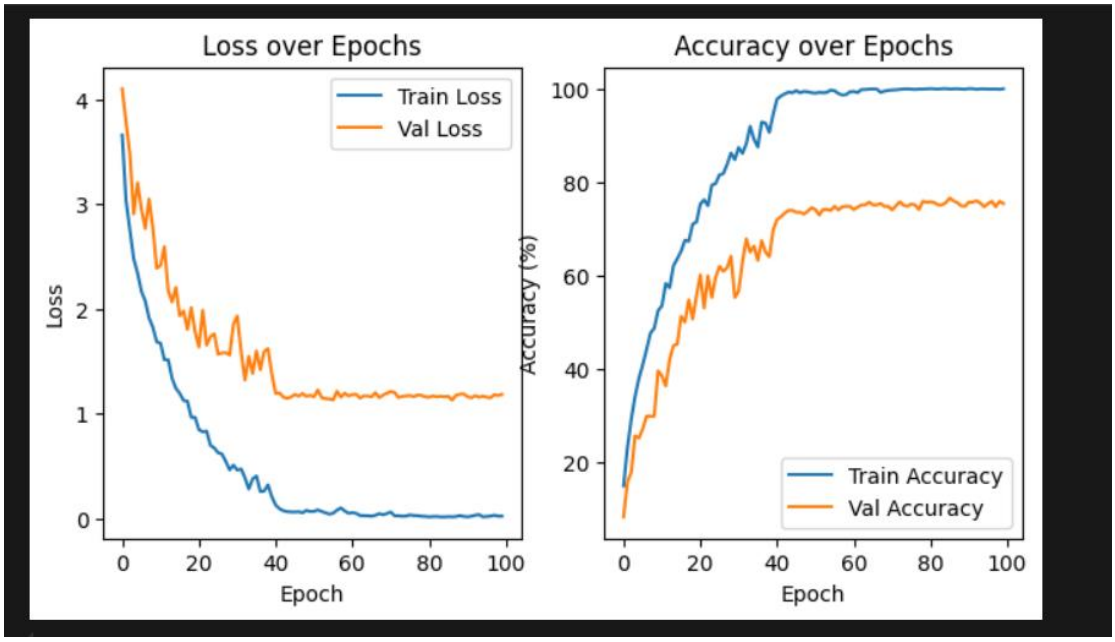

Case3 相對於 Case1 來說差距其實也沒有很大，收斂效果也因為使用 lr_scheduler 顯得很不錯，但對於比較兩者差異來說，也許是沒有特別大的梯度和 learning rate 所以沒有辦法發揮 LeakReLU 的優勢.

Example:

最後則是 Example 對於使用 ResNet 的比較，範例所使用的是單純兩層 Conv+3 層全連接層的 CNN 架構，可以很明顯發現 Residualblock 是有多麼的有效，可以透過誤差計算來增加準確率，效果很明顯好的非常多. 在實作完後，造成這種情況的原因主要在優化器的選擇，和誤差計算的使用，這是十分聰明且有趣的一個想法.